

Disentanglement 与 β -VAE 笔记

CS236 自学笔记 —— VAE on MNIST 项目

July 3, 2026

1 Disentanglement 的基本直觉

1.1 生成因子 (generative factors)

一张图片的生成过程，可以看作若干相对独立的”决定”共同作用的结果。以 MNIST 为例：数字类别（0-9）、笔画粗细、倾斜角度、大小等，这些因子在现实中往往彼此独立——选择写哪个数字，并不限制笔画粗细或倾斜角度。这些独立的、决定数据外观的隐藏变量，称为**生成因子**。

1.2 纠缠 vs 解耦表示

VAE 的隐变量 $z \in \mathbb{R}^d$ 是隐空间的一个坐标系统。

纠缠 (entangled) 表示：沿某一坐标轴移动会同时改变多个语义属性，信息混合在一起，没有哪一根轴单独对应一个可解释的因子。

解耦 (disentangled) 表示：存在某根轴 z_i ，只改变其取值就只改变图像的一个语义属性（如笔画粗细），其余属性（数字类别、角度等）保持不变。理想情况下，隐空间坐标轴与真实生成因子一一对齐。

1.3 解耦表示的价值

- **可解释性：**每个维度对应明确语义，而非黑箱数字。
- **可控生成/编辑：**沿单一维度平移即可独立改变某个属性（原始 β -VAE 论文在 CelebA 人脸数据集上展示了姿态、光照、是否戴眼镜等属性的独立控制）。
- **组合泛化：**若各因子对应独立维度，模型可以自由组合训练时未见过的因子搭配。
- **下游任务样本效率：**解耦的特征对下游分类/回归任务往往需要更少标注数据。

2 Vanilla VAE 为何不会自动解耦

标准 VAE 的 ELBO：

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - \text{KL}(q_\phi(z|x) \parallel p(z)), \quad p(z) = \mathcal{N}(0, I).$$

旋转对称性论证：先验 $\mathcal{N}(0, I)$ 是各向同性的——对任意正交矩阵 R （满足 $R^\top R = I$ ），若令 $z' = Rz$ ，则 z' 的边缘分布仍为 $\mathcal{N}(0, I)$ 。据此可以构造一个新模型：编码器输出后先乘 R ，解码器先乘

R^{-1} 再解码。新模型的 ELBO 与原模型完全相等（KL 项因旋转不敏感而不变，重建项因解码器多做的逆旋转而抵消）。

也就是说，目标函数分辨不出“解耦坐标系”与“任意旋转过的纠缠坐标系”哪个更好——两者在 loss 看来完全等价。既然目标函数没有偏好，**标准 VAE 没有任何机制促使模型收敛到轴对齐的解耦表示**，最终学到哪种坐标系纯粹取决于优化过程的随机性，通常是纠缠的。

3 β -VAE

3.1 目标函数

在 KL 项前引入权重 β (Higgins et al., ICLR 2017)：

$$\mathcal{L}_\beta(\theta, \phi; x) = \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - \beta \cdot \text{KL}(q_\phi(z|x) \| p(z)).$$

写成最小化 loss 的形式： $\mathcal{L} = \text{Recon} + \beta \cdot \text{KL}$ 。 $\beta = 1$ 时退化为标准 VAE。改动量很小——只需修改损失函数里的一个系数，不需要改变网络结构。

3.2 信息瓶颈视角：为什么增大 β 促成解耦

KL 项可以理解为对互信息 $I(x; z)$ 的上界约束，即 z 这个“信道”允许传递的、关于 x 的信息量上限； β 越大，约束越紧。

在对角协方差假设 $q_\phi(z|x) = \mathcal{N}(\mu(x), \text{diag}(\sigma^2(x)))$ 下，KL 项可以按维度精确拆分：

$$\text{KL}(q_\phi(z|x) \| p(z)) = \sum_{j=1}^d \text{KL}(q_\phi(z_j|x) \| \mathcal{N}(0, 1)).$$

即“信息预算”是按维度独立分摊的。在总预算受限的情况下，最经济的编码策略是让每个维度只承载一个独立、“性价比”最高的生成因子，而不是把多个因子冗余地混在同一维度里（冗余编码在重建收益不变的前提下会消耗更多 KL 预算，不划算）。 β 越大，这种“精打细算”的压力越强，模型被迫趋向更接近轴对齐（解耦）的编码方式 (Burgess et al., 2017)。 $\beta = 1$ 时压力不足，纠缠不会被显著惩罚，前述旋转对称性论证依然成立。

3.3 Trade-off: 重建质量 vs Latent Regularization

β 增大 $\Rightarrow$ 后验 $q_\phi(z|x)$ 被迫更贴近先验 $\Rightarrow$ 不同样本编码出的 z 彼此差异变小，传递给解码器的信息量减少 $\Rightarrow$ **重建质量下降**（模型优先保留对重建贡献最大的核心信息，牺牲笔画粗细、角度等次要因子）。这就是“重建精度”与“latent regularization”（ z 贴近先验、维度独立）此消彼长的本质——两者在争夺同一份有限的信息预算。

3.4 极端情况：Posterior Collapse

若 β 过大，模型可能采取 $\mu(x) \approx 0, \sigma(x) \approx 1$ 的策略——对所有输入都输出几乎相同的 z （此时 KL 项精确趋于 0），编码器不再传递任何关于 x 的具体信息。解码器收到的 z 与输入无关，只能学会对任意输入输出数据集“平均意义上”的模糊图像，重建质量严重恶化，此时“解耦”已无意义。

因此存在一个合理的 β 取值区间：过小时正则化压力不足，纠缠依旧；过大则可能引发大范围坍缩，模型停止编码有效信息。

4 诊断工具

4.1 Latent Interpolation (隐空间插值)

给定两个真实样本 x_a, x_b ，编码得到 μ_a, μ_b ，在两点间线性插值

$$z(\alpha) = (1 - \alpha) \mu_a + \alpha \mu_b, \quad \alpha \in [0, 1],$$

逐点解码。用于检验隐空间的**连续性**：过渡是否平滑、中间态是否仍是合理图像。这只能说明隐空间“连续”，不直接说明“解耦”，两者是相关但不同的概念。

4.2 Latent Traversal (逐维度扫描)

固定除第 i 维外的所有维度，令 z_i 在某区间内均匀取值，其余维度不变，观察输出如何变化。用于定性检验**解耦程度**：若扫描某一维时只有单一属性变化，说明该维度语义纯净；若多个属性同时变化，说明仍然纠缠。这是原始 β -VAE 论文中评估 disentanglement 的经典画法。

4.3 活跃维度 (active units)

维度坍缩 ($\mu \rightarrow 0, \sigma \rightarrow 1$) 会导致该维度对扫描不敏感——解码器已学会忽略它。坍缩维度的数量反映了压缩/正则化的程度，但**坍缩维度少不等价于活跃维度已经解耦**，仍需对活跃维度逐一做定性检验。

5 小结

- Disentanglement 追求隐空间坐标轴与真实生成因子对齐；标准 VAE 的目标函数不具备促成这一点的机制（旋转对称性论证）。
- β -VAE 通过加权 KL 项，从信息瓶颈的角度对隐空间施加更强的压缩压力，间接鼓励维度独立、语义单一的编码方式。
- β 的选择需要在重建质量与正则化强度之间权衡：过大会导致维度坍缩，甚至后验完全坍缩。
- Latent interpolation 检验连续性，latent traversal 检验解耦；两者共同构成对 β -VAE 效果的定性评估工具。

参考文献

Higgins, I., Matthey, L., Pal, A., Burgess, C., Glorot, X., Botvinick, M., Mohamed, S., & Lerchner, A. (2017). β -VAE: Learning Basic Visual Concepts with a Constrained Variational Framework. ICLR.

Burgess, C. P., Higgins, I., Pal, A., Matthey, L., Watters, N., Desjardins, G., & Lerchner, A. (2017). Understanding disentangling in β -VAE. NeurIPS Workshop on Learning Disentangled Representations.